



5 - Modèles ARIMA

ALAIN QUARTIER-LA-TENTE

Objectifs de cette séquence

- Notions sur la stationnarisation et la différenciation
- Modèles (S)ARIMA

Questions de positionnement

Qu'est-ce qu'un processus stationnaire ?

Tendance, cycle, saisonnalité sont-ils des processus stationnaires ?

Que signifie "ARIMA" et que reflète un tel modèle ?

Comment se comportent les erreurs de prévision d'un modèle ARIMA ?

Qu'est-ce qu'un SARMA ?

Y a-t-il un lien entre ARIMA et ETS ?

Quelques définitions (1/2)

Série temporelle : suite de variables aléatoires $(X_t)_t$ dont on observe une réalisation $(X_t(\omega))_t$

La suite $(X_t)_t$ est appelée *processus stochastique*

Un processus est dit *stationnaire* lorsque la loi de X_t n'évolue pas dans le temps : distribution $\forall s, (X_t, \dots, X_{t+s})$ indépendante du temps

$\implies$ série plus ou moins horizontale et de variance constante

➔ Notion pour faire l'inférence et construire un modèle ARIMA

Quelques définitions (2/2)

Stationnarité, hypothèse invérifiable ➡ en pratique processus *faiblement stationnaire* :

- les moments d'ordre 2 existent
- espérance constante
- covariance entre t et $t - h$ ne dépend pas du temps, mais de la distance h
⇒ variance constante

Exemple : un bruit blanc, i.e. :


- espérance nulle
- covariance entre t et $t - h$ nulle, pour tout $h \neq 0$
- variance non nulle et constante

Comment identifier une série non-stationnaire (en niveau) ?


- Tracer le chronogramme
- Etudier l'ACF :
 - Série non-stationnaire : tend lentement vers 0 et $\hat{\rho}(1)$ souvent positif et élevé
 - Série stationnaire : tend rapidement vers 0

Exemple


Nombre de résidents australiens



Series: austres



Exemple



La différenciation pour stabiliser le niveau

- Si la série différenciée est un bruit blanc de moyenne nulle (marche aléatoire) :

$$(I - B)y_t = y_t - y_{t-1} = \varepsilon_t \implies y_t = y_0 + \sum_{i=1}^t \varepsilon_i$$

➔ Modèle naïf

Généralement mouvement à la hausse ou à la baisse aléatoire,

- Si la série différenciée est un bruit blanc de moyenne non nulle (marche aléatoire avec dérive / *drift*) :

$$(I - B)y_t = c + \varepsilon_t \implies y_t = y_0 + ct + \sum_{i=1}^t \varepsilon_i$$

- Parfois on a besoin de différencier plusieurs fois
 $(I - B)^2 y_t = (y_t - y_{t-1}) - (y_{t-1} - y_{t-2})$ ou de faire une différenciation saisonnière $(I - B^m)y_t = y_t - y_m$
- Si saisonnalité importante, commencer par la différenciation saisonnière

Modèles Intégrés (1/3)

Soit X , processus « tendance linéaire » :

$$X_t = \alpha + \beta t + \varepsilon_t$$

Calculer l'espérance et la variance de la v.a. X_t ?

X est stationnaire ?

Différence d'ordre 1 :

$$(I - B)X_t = ?$$

La série obtenue est-elle stationnaire ?

Si X est un processus « tendance polynomiale d'ordre 2 », comment stationnariser la série ?

Modèles Intégrés (2/3)

Soit X , processus « saisonnier stable » :

$$X_t = S_t + \varepsilon_t \quad \text{avec} \quad \forall t, S_t = S_{t+s}$$

X stationnaire ?

Différence d'ordre 1, avec retard d'ordre s :

$$(I - B^s)X_t = ?$$

La série obtenue est-elle stationnaire ?

Si $X_t = a + bt + S_t + \varepsilon_t$, que donnerait cette différenciation ?

Modèles Intégrés (3/3)

Une différenciation « simple » d'ordre d supprime les tendances polynomiales d'ordre d :

$$(I - B)^d X_t$$

Une différenciation « saisonnière » supprime aussi les tendances linéaires :


$$(I - B^s) X_t$$

Une différenciation « saisonnière » d'ordre D plus grand que 1 est rare :

$$(I - B^s)^D X_t$$


Exemple

```
autoplot(co2)
```




Exemple

```
autoplot(diff(co2, 12))
```



Exemple

```
autoplot(diff(diff(co2, 12), 1))
```



Faut-il toujours différencier ?

Pour modéliser une série avec tendance on peut distinguer deux types de non-stationnarité :

1. Modèle trend-stationnaire :

$$X_t = a + bt + \varepsilon_t$$

2. Modèle avec racine unité


$$(1 - B)Y_t = b + \eta_t \implies Y_t = a + bt + \underbrace{\sum_{i=1}^t \eta_i}_{\text{tend. stochastique}}$$

On a $\mathbb{V}[X_t] = \mathbb{V}[\varepsilon_t] = \text{cst}$ indépendante du temps mais $\mathbb{V}[Y_t] = t\mathbb{V}[\eta_t]$


Exemple

```
set.seed(1); e = rnorm(100)
u1 = ts(cumsum(e), start = 2000, frequency = 12)
u2 = ts(e + seq_along(e)/50, start = 2000, frequency = 12)
m1 = Arima(u1, order = c(0, 1, 0))
m2 = Arima(u2, include.drift = TRUE)
(autoplot(u1, y = NULL, main = "Marche aléatoire") +
  autolayer(forecast(m1, h = 12))) /
(autoplot(u2, y = NULL, main = "Trend-stationnaire") +
  autolayer(forecast(m2, h = 12)))
```

Marche aléatoire



Trend-stationnaire



Tests de racine unitaire

Plusieurs tests existent pour déterminer l'ordre de différenciation :

- Sur séries non-saisonnnières :
 - Test de Dickey-Fuller augmenté (ADF) `fUnitRoots::adfTest()`, `tseries::adf.test()`, `urca::ur.df()`. (H_0) racine unitaire (avec ou non tendance linéaire)
 - Test de Phillips-Perron `tseries::pp.test`, `urca::ur.pp` ou `feasts::unitroot_pp()`. (H_0) racine unitaire (avec ou non tendance linéaire)
 - Test KPSS `tseries::kpss.test()` ou `urca::ur.kpss()`. (H_0) série stationnaire (avec ou non tendance linéaire)
- Pour les séries saisonnières : d'autres tests du type Canova-Hansen (`uroot::ch.test`), F-Tests, etc.

`forecast::ndiffs()` (ou `feasts::unitroot_ndiffs`) et `forecast::nsdiffs()` (ou `feasts::unitroot_nsdiffs`) permettent de déterminer les ordres de différenciation en utilisant ces tests.

Exemple (1)

```
uroot::ch.test(co2)
```

Canova and Hansen test for seasonal stability

```
data: co2
```

	statistic	pvalue
Jan	2.3112	0 ***
Feb	2.3104	0 ***
Mar	2.3137	0 ***
Apr	2.3156	0 ***
May	2.3158	0 ***
Jun	2.3152	0 ***
Jul	2.3142	0 ***
Aug	2.3155	0 ***
Sep	2.3128	0 ***
Oct	2.3135	0 ***
Nov	2.3136	0 ***
Dec	2.3148	0 ***
joint	2.9814	0.0476 *

Exemple (2)

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Test type: seasonal dummies

NW covariance matrix lag order: 18

First order lag: no

Other regressors: no

P-values: based on response surface regressions

```
uroot::ch.test(diff(co2, 12))
```

Canova and Hansen test for seasonal stability

data: diff(co2, 12)

	statistic	pvalue	
Jan	0.8938	0.003	**
Feb	0.7737	0.0067	**
Mar	0.5276	0.0327	*
Apr	0.6513	0.0149	*
May	0.6378	0.0162	*

Exemple (3)

```
Jun      0.6103 0.0193 *
Jul      0.5519 0.0281 *
Aug      0.5907 0.0219 *
Sep      0.6174 0.0185 *
Oct      0.7576 0.0075 **
Nov      0.8991 0.0029 **
Dec      1.0098 0.0014 **
joint    1.3838 0.5406
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Test type: seasonal dummies
```

```
NW covariance matrix lag order: 18
```

```
First order lag: no
```

```
Other regressors: no
```

```
P-values: based on response surface regressions
```

```
forecast::nsdiffs(co2) # Autre test que Canova-Hansen est utilisé
```

```
[1] 1
```

Exemple (4)

```
tseries::kpss.test(diff(co2, 12))
```

KPSS Test for Level Stationarity

```
data: diff(co2, 12)
```

KPSS Level = 1.9439, Truncation lag parameter = 5, p-value = 0.01

```
tseries::kpss.test(diff(diff(co2, 12), 1))
```

KPSS Test for Level Stationarity

```
data: diff(diff(co2, 12), 1)
```

KPSS Level = 0.011476, Truncation lag parameter = 5, p-value = 0.1

```
forecast::ndiffs(diff(co2, 12))
```

```
[1] 1
```

La partie « modélisation ARIMA »

ARIMA, modèle auto-projectif :

$$X_t = f(X_{t-1}, X_{t-2}, X_{t-3}, \dots, \varepsilon_t, \varepsilon_{t-1}, \varepsilon_{t-2} \dots)$$

Trouver f ?

Sous hypothèse de stationnarité, il existe un « modèle ARMA » qui approche la série.

Conséquence (th de Wold) : erreurs de prévision se comportent comme le résidu du modèle (bruit blanc)

On privilégie les modèles avec faible nombre de paramètres.

Méthode de Box et Jenkins pour estimer et juger de la qualité des modèles.

Modèles Autorégressifs (AR)

Modèle *autorégressif* d'ordre p , $AR(p)$:

$$\begin{aligned} X_t &= \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t \\ \iff (1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p) X_t &= \varepsilon_t \\ \iff \Phi(B) X_t &= \varepsilon_t \end{aligned}$$





On retrouve les marches aléatoires (sans ou avec dérive)

Un AR modélise l'influence des p réalisations passées sur la réalisation courante : effet mémoire (on a beaucoup vendu la semaine dernière, X_{t-1} on va sûrement beaucoup vendre cette semaine, X_t)

Exemples classiques (voir TP)

- Le niveau du lac Huron peut être modélisé par un $AR(1)$ ou un $AR(2)$;
- $AR(2)$: nombre de tâches solaires - Yules

Exemples : que dire sur ϕ_1 ?



Exemples : réponse

Dans les graphiques de droite on observe une alternance entre périodes positives et négatives : $\phi_1 < 0$

```
set.seed(100)
ar1_pos = arima.sim(n=600, list(ar=0.8))
ar1_neg = arima.sim(n=600, list(ar=-0.8))
ar2_pos = arima.sim(n=600, list(ar=c(0.3, 0.2)))
ar2_neg = arima.sim(n=600, list(ar=c(-0.3, 0.2)))
(autoplot(ar1_pos, main = "AR(1)", y = NULL) +
  autoplot(ar1_neg, main = "AR(1)", y = NULL)) /
  (autoplot(ar2_pos, main = "AR(2)", y = NULL) +
    autoplot(ar2_neg, main = "AR(2)", y = NULL)
  )
```

Reconnaitre un modèle $AR(p)$

Pour reconnaître un $AR(p)$ on peut analyser l'autocorrélogramme partiel (PACF) : $r(k)$ mesure relation entre y_t et y_{t-k} en enlevant les effets de $y_{t-1}, \dots, y_{t-k-1}$

α_k est le coefficient ϕ_k dans la régression

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_k y_{t-k} + \varepsilon_t$$


On a $r(1) = \rho(1)$

Pour un $AR(p)$:


- **ACF** : $\rho(h)$ décroît exponentiellement vers 0 (ou de manière sinusoïdale si $\phi_1 < 0$)
- **PACF** : $r(h) = 0$ pour $h > p$

Exemple $AR(2)$ $y_t = 0.3y_{t-1} + 0.2y_{t-2} + \varepsilon_t$

$$AR(2) \ y_t = 0.3y_{t-1} + 0.2y_{t-2} + \varepsilon_t$$



$$AR(2) \ y_t = 0.3y_{t-1} + 0.2y_{t-2} + \varepsilon_t$$



Conditions de stationnarité

On restreint généralement les modèles autorégressifs aux modèles stationnaires

Pour cela il faut que les racines de Φ soient en dehors du cercle unité (sinon un choc pourrait avoir un effet permanent)

Modèles « Moving Average » (MA)

Modèle *moyenne mobile* d'ordre q , $MA(q)$:


$$\begin{aligned} X_t &= \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q} \\ \iff X_t &= (1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q) \varepsilon_t \\ \iff X_t &= \Theta(B) \varepsilon_t \end{aligned}$$

Rmq : dans certains logiciels/packages (e.g. R/JDemetra) on utilise plutôt la notation $X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}$


Résulte d'une accumulation non persistante de q chocs indépendants : effet mémoire des erreurs passées (la semaine dernière il s'est passé un événement bizarre et imprévu, le système est encore un peu perturbé aujourd'hui par contagion)

Exemples


MA(1)




MA(1)



MA(2)



MA(2)



Reconnaitre un modèle $MA(q)$

Pour reconnaître un $MA(q)$ on peut analyser l'autocorrélogramme (ACF)


Pour un $MA(q)$:

- **ACF** : $\rho(h) = 0$ pour $h > q$
- **PACF** : $r(h) = 0$ décroît exponentiellement vers 0


Exemple d'un $MA(3)$

$$y_t = \varepsilon_t + 0.8\varepsilon_{t-1} + 0.5\varepsilon_{t-2} + 0.6\varepsilon_{t-3}$$

$$MA(3) \ y_t = \varepsilon_t + 0.8\varepsilon_{t-1} + 0.7\varepsilon_{t-2} + 0.6\varepsilon_{t-3}$$



$$MA(3) \ y_t = \varepsilon_t + 0.8\varepsilon_{t-1} + 0.7\varepsilon_{t-2} + 0.6\varepsilon_{t-3}$$



Modèles ARMA

Modèles $ARMA(p, q)$: combine $AR(p)$ et $MA(q)$, sans ou avec constante

$$\Phi(B)X_t = \Theta(B)\varepsilon_t$$

$$\Phi(B)X_t = \mu + \Theta(B)\varepsilon_t$$

Modèles SARMA

Modèle $SARMA(P, Q)$: $ARMA$ avec polynôme d'ordre s (4 séries trimestrielles, 12 séries mensuelles) :

$$\Phi(B^s)X_t = \Theta(B^s)\varepsilon_t \text{ ou } \Phi_s(B)X_t = \Theta_s(B)\varepsilon_t$$

Intérêt :

- montrer autocorrélations d'ordre s
- simplifier l'écriture par factorisation

$ARMA(p, q)(P, Q)$ combine parties régulière et saisonnière :
 $ARMA(p, q) \times SARMA(P, Q)$.

Identique à $ARMA(p + P * s, q + Q * s)$

Exemple série mensuelle : $ARMA(1, 1)(1, 1) = ARMA(13, 13)$

Modèles ARIMA

$ARIMA(p, d, q)$ modélise les séries non stationnaires avec tendance

$$\Phi(B)(I - B)^d X_t = \Theta(B)\varepsilon_t$$

$ARIMA(p, d, q)(P, D, Q)$ modélise les séries avec tendance et saisonnalité

$$\Phi(B)\Phi_s(B)(I - B)^d(I - B^s)^D X_t = \Theta(B)\Theta_s(B)\varepsilon_t$$

Factorisation des polynômes en B de la partie *régulière* et de la partie *saisonnière*

Modèle le plus souvent observé : $ARIMA(0, 1, 1)(0, 1, 1)$ appelé modèle Airline (voir TP)

Méthode de Box-Jenkins

1. Stationnariser le processus : d, D
2. Identifier les ordres ARMA : p, P, q, Q ➡ structure d'autocorrélation de la série
3. Estimer les coefficients ARMA ➡ degré de variabilité de la structure d'autocorrélation
➡ Peut-on simplifier le modèle ?
4. Valider le modèle ➡ résidus = bruit blanc ?
5. Choix du modèle (si plusieurs modèles valides) ➡ critères d'information
6. Prévision

Méthode générale

- Tracer la série : transformation nécessaire ? Points atypiques ?
- Stationnariser la série pour déterminer D puis d (analyse graphique et/ou tests)
- Examen des ACF/PACF pour déterminer des ordres P, Q, p, q plausibles
- Sélection des modèles par minimisation AICc
- Vérifier la qualité des résidus : si ne ressemble pas à un bruit blanc changer de modèle
- Préviation

Méthode utilisée dans `forecast::auto.arima()` (1)

1. On choisit D (STL utilisé et non pas test de Canova-Hansen) puis d déterminé en utilisant des tests successifs de KPSS.
2. Sélection d'un des 4 modèles en minimisant l'AICc :
 $ARIMA(2, d, 2)(1, D, 1)$, $ARIMA(2, d, 2)(0, D, 0)$, $ARIMA(1, d, 0)(1, D, 0)$
et $ARIMA(0, d, 1)(0, D, 1)$
3. On considère 30 variations du modèle retenu :
 - En faisant varier un seul des paramètres p , q , P ou Q de ± 1 ;
 - En faisant varier p et q en même temps de ± 1 ;
 - En faisant varier P et Q en même temps de ± 1 ;
 - En incluant ou non la constante.
 - Si un modèle minimise l'AICc on recommence.

Méthode utilisée dans `forecast::auto.arima()` (2)

Si on n'a qu'une série, utiliser `forecast::auto.arima(., stepwise = FALSE, approximation = FALSE)` pour étudier tous les modèles (plus lent).

D'autres algorithmes (TRAMO ou pickmdl) utilisent également d'autres tests : autocorrélation (Ljung-Box à l'ordre $2m$), tests de sur-différenciation, de passage au log.

Équivalence entre ARIMA et ETS

Il y a plusieurs équivalences entre ETS et ARIMA :

- Modèles exponentiels linéaires sont tous des cas particulier de modèle ARIMA
- Modèles exponentiels non linéaires n'ont pas d'équivalent ARIMA
- De nombreux ARIMA n'ont pas de modèle ETS équivalent
- Les modèles ETS sont non-stationnaires

Exemple 1 : $ETS(A, N, N)$

$$\begin{cases} y_t &= l_{t-1} + \varepsilon_t \\ l_t &= l_{t-1} + \alpha \varepsilon_t \end{cases} \implies y_t = (y_{t-1} - \varepsilon_{t-1} + \alpha \varepsilon_{t-1}) + \varepsilon_t$$

Donc $y_t \sim ARIMA(0, 1, 1)$:

$$(1 - B)y_t = (1 + (\alpha - 1)B)\varepsilon_t$$

Exemple 2 : $ETS(A, A, N)$

$$\begin{cases} y_t = l_{t-1} + b_{t-1} + \varepsilon_t \\ l_t = l_{t-1} + b_{t-1} + \alpha \varepsilon_t \\ b_t = b_{t-1} + \beta \varepsilon_t \end{cases} \iff \begin{cases} y_t = l_{t-1} + b_{t-1} + \varepsilon_t \\ (1-B)l_t = b_{t-1} + \alpha \varepsilon_t \\ (1-B)b_t = \beta \varepsilon_t \end{cases}$$

D'où

$$\begin{aligned} (1-B)^2 y_t &= (1-B)B(Bb_t + \alpha \varepsilon_t) + (1-B)B\beta \varepsilon_t + (1-B)^2 \varepsilon_t \\ &= B^2 \beta \varepsilon_t + (1-B)B(\beta + \alpha) \varepsilon_t + (1-2B+B^2) \varepsilon_t \\ &= [1 + (\alpha + \beta - 2)B + (1-\alpha)B^2] \varepsilon_t \end{aligned}$$

et $y_t \sim ARIMA(0, 2, 2)$

Exemple 3 : $ETS(A, A, A)$

$$\begin{cases} y_t = l_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t \\ l_t = l_{t-1} + b_{t-1} + \alpha \varepsilon_t \\ b_t = b_{t-1} + \beta \varepsilon_t \\ s_t = s_{t-m} + \gamma \varepsilon_t \end{cases} \iff \begin{cases} y_t = B l_t + B b_t + B^m s_t + \varepsilon_t \\ (1-B) l_t = B b_t + \alpha \varepsilon_t \\ (1-B) b_t = \beta \varepsilon_t \\ (1-B^m) s_t = \gamma \varepsilon_t \end{cases}$$

$$\begin{aligned} (1-B)(1-B^m)y_t &= (1-B^m)B^2b_t + (1-B^m)B\alpha\varepsilon_t + (1-B^m)B\beta\varepsilon_t + \\ &\quad (1-B)B^m\gamma\varepsilon_t + (1-B)(1-B^m)\varepsilon_t \\ &= \left[(1+B+\dots+B^{m-1})B^2\beta + (1-B^m)B(\alpha+\beta) + \right. \\ &\quad \left. (1-B)B^m(\gamma-1) + (1-B) \right] \varepsilon_t \end{aligned}$$

Donc $y_t \sim ARIMA(0, 1, m+1)(0, 1, 0)$

Comparaison des modèles ETS et ARIMA

Peut-on comparer les modèles ETS et ARIMA en utilisant un critère d'information ?



NON ! Attention aux ordres de différenciation, sur un modèle ARIMA ne comparer par exemple que les modèles qui ont le même ordre de différenciation

... Mais quid lorsque les modèles sont équivalents : peut-on comparer $ETS(A, A, A)$ avec un $ARIMA(0, 1, 1)(0, 1, 1)$?



Encore NON ! Avec un modèle ARIMA, lorsqu'il y a différenciation on perd les premières données alors que pour un ETS on a des prévisions sur toutes les données.

Principe de TRAMO

TRAMO = Time series Regression with ARIMA noise, Missing values and Outliers

Objectifs de TRAMO :

- corriger la série de points atypiques, des effets de calendrier et imputation des valeurs manquantes
- prolonger la série
- fournir à SEATS le modèle ARIMA à la base de la décomposition

$$Y_t = \sum \hat{\alpha}_i O_{it} + \sum \hat{\beta}_j C_{jt} + \varepsilon_t$$

Et on modélise $(Y_t - \sum \hat{\alpha}_i O_{it} + \sum \hat{\beta}_j C_{jt}) = \varepsilon_t$ comme un modèle ARIMA

Principe de SEATS (1/3)

SEATS = Signal Extraction in ARIMA Time Series

SEATS utilise le modèle ARIMA de la série linéarisée TRAMO :

$$\underbrace{\Phi(B)\Phi_s(B)(I-B)^d(I-B^s)^D}_{\Phi(B)} X_t = \underbrace{\Theta(B)\Theta_s(B)}_{\Theta(B)} \varepsilon_t$$

Hypothèses :

1. La série linéarisée peut être modélisée par un modèle ARIMA
2. Les différentes composantes sont décorrélées et chaque composante peut être modélisée par un modèle ARIMA
3. Les polynômes AR des composantes n'ont pas de racine commune

Principe de SEATS (2/3)

On factorise le polynôme AR $\Phi(B)$:

$$\Phi(B) = \phi_T(B)\phi_S(B)\phi_C(B)$$

- $\phi_T(B)$ racines correspondant à la tendance
- $\phi_S(B)$ racines correspondant à la saisonnalité
- $\phi_C(B)$ racines correspondant au cycle

Principe de SEATS (3/3)

X_t est exprimé sous la forme :

$$X_t = \frac{\Theta(B)}{\Phi(B)} \varepsilon_t = \underbrace{\frac{\theta_T(B)}{\phi_T(B)} \varepsilon_{T,t}}_{\text{Tendance}} + \underbrace{\frac{\theta_S(B)}{\phi_S(B)} \varepsilon_{S,t}}_{\text{Saisonnalité}} + \underbrace{\frac{\theta_C(B)}{\phi_C(B)} \varepsilon_{C,t}}_{\text{Cycle}} + \underbrace{\nu_t}_{\text{Irrégulier (bruit blanc)}}$$

Un modèle ARIMA est associé à chaque composante.

Infinité de solutions : on retient celle qui minimise la variance de l'irrégulier

➔ Estimation par filtre de Wiener-Kolmogorov

Les essentiels

Les séries économiques ne sont pas stationnaires, ni leur niveau, ni leurs fluctuations ne sont constants dans le temps

Intégrer un processus permet de le stationnariser

Un MA capte les fluctuations non persistantes autour d'un niveau constant - processus stationnaire

Un AR met en évidence l'influence des réalisations passées sur la réalisation courante

Un ARIMA reflète la structure des autocorrélations de la série, ainsi que le degré de sa variabilité dans le temps

L'examen des résidus permet de valider les modèles, le choix "optimal" se fait grâce aux critères d'information

Bibliographie

Hyndman, R.J., & Athanasopoulos, G. (2018) *Forecasting: principles and practice*, 2nd edition, OTexts: Melbourne, Australia. [OTexts.com/fpp2](https://otexts.com/fpp2). Accessed on may 2026.

Hyndman, R.J., & Athanasopoulos, G. (2021) *Forecasting: principles and practice*, 3rd edition, OTexts: Melbourne, Australia. [OTexts.com/fpp3](https://otexts.com/fpp3). Accessed on may 2026.