



6 - Compléments

ALAIN QUARTIER-LA-TENTE

Objectifs de cette séquence

- Présenter quelques compléments sans exercice associé

Régresseurs externes classiques

Dans certaines méthodes (régression linéaire, ARIMA, etc. mais pas ETS) permettent de rajouter des régresseurs externes qui peuvent aider à l'analyse/prévision

- polynômes sur les dates (e.g. tendance linéaire) (on peut s'aider de `forecast::tslm()`)

Régresseurs externes classiques

Dans certaines méthodes (régression linéaire, ARIMA, etc. mais pas ETS) permettent de rajouter des régresseurs externes qui peuvent aider à l'analyse/prévision

- polynômes sur les dates (e.g. tendance linéaire) (on peut s'aider de `forecast::tslm()`)
- indicatrices sur la périodicité (avec variable de contraste) :
 - Sur les jours de la semaine
 - Sur les mois/trimestres

Régresseurs externes classiques

Dans certaines méthodes (régression linéaire, ARIMA, etc. mais pas ETS) permettent de rajouter des régresseurs externes qui peuvent aider à l'analyse/prévision

- polynômes sur les dates (e.g. tendance linéaire) (on peut s'aider de `forecast::tslm()`)
- indicatrices sur la périodicité (avec variable de contraste) :
 - Sur les jours de la semaine
 - Sur les mois/trimestres
- Régresseurs JO :
 - On compte le nombre de lundis, mardis, ... dans le mois et on construit des variables contraste (en faisant des éventuels regroupement)
 - Régresseurs sur les jours fériés (éventuellement regroupés avec dimanches) + éventuels effets graduels (notamment fêtes mobiles)

Régresseurs de Fourier

Lorsque la périodicité est trop élevée ou lorsqu'il y a plusieurs saisonnalités, ajouter des indicatrices peut être trop coûteux.

Solution : ajouter des variables sinusoïdales aux fréquences étudiées !

$$\cos\left(\frac{2k\pi}{m}\right) \quad \sin\left(\frac{2k\pi}{m}\right) \quad \text{avec } 0 < k < m$$

Généralement $k \ll m$ lorsque m est grand

Régresseurs de Fourier

Lorsque la périodicité est trop élevée ou lorsqu'il y a plusieurs saisonnalités, ajouter des indicatrices peut être trop coûteux.

Solution : ajouter des variables sinusoïdales aux fréquences étudiées !

$$\cos\left(\frac{2k\pi}{m}\right) \quad \sin\left(\frac{2k\pi}{m}\right) \quad \text{avec } 0 < k < m$$

Généralement $k \ll m$ lorsque m est grand

- Pour séries mensuelles : $m = 12$
- Pour les séries hebdomadaires $m = 365.25/7 \simeq 52$
- Pour les séries journalières $m = 365.25$ pour saisonnalité annuelle, $m = 365.25/12 \simeq 30$ pour saisonnalité mensuelle.

TBATS (1)

Une transformation de Box-Cox est utilisée :

$$y_t^{(\lambda)} = \begin{cases} \frac{y_t^\lambda - 1}{\lambda} & \text{if } \lambda \neq 0 \\ \log(y_t) & \text{if } \lambda = 0 \end{cases}$$

Ensuite un modèle avec *Trigonometric seasonality, ARMA errors, Trend and Seasonal components* est calculé : c'est tout ce que l'on a vu dans les précédents cours.

Voir `?forecast::tbats()`

TBATS (2)

$$\begin{cases} y_t^{(\lambda)} = l_{t-1} + \phi b_{t-1} + \sum_{i=1}^T s_{t-m_i}^{(i)} + d_t \text{ and } d_t \sim \text{ARMA}(p, q) \\ l_t = l_{t-1} + \phi b_{t-1} + \alpha d_t \\ b_t = \phi b_{t-1} + \beta d_t \end{cases}$$

$$\begin{cases} s_t^{(i)} = \sum_{j=1}^{k_i} s_{j,t}^{(i)} \\ s_{j,t}^{(i)} = s_{j,t-1}^{(i)} \cos \omega_j + s_{j,t-1}^{*(i)} \sin \omega_j + \gamma_1^{(i)} d_t \\ s_{j,t-1}^{*(i)} = s_{j,t-1}^{(i)} \sin \omega_j + s_{j,t-1}^{*(i)} \cos \omega_j + \gamma_2^{(i)} d_t \end{cases} \quad \text{and } \omega_j = \frac{2\pi j}{m_i}$$

Notation : $TBATS(\omega, p, q, \phi, \langle m_1, k_1 \rangle, \dots, \langle m_J, k_J \rangle)$ avec

- ω = paramètre de Box-Cox
- (p, q) = ARMA(p,q)
- ϕ = paramètre d'amortissement
- $m_1, \dots, m_J$ les périodicités et $k_1, \dots, k_J$ le nombre de termes de fourrier

TBATS (3)

```
library(forecast)
tbats(USAccDeaths)
```

```
TBATS(1, {0,0}, -, {<12,5>})
```

```
Call: tbats(y = USAccDeaths)
```

Parameters

```
Alpha: 0.5950012
```

```
Gamma-1 Values: -0.01207202
```

```
Gamma-2 Values: 0.01159708
```

Seed States:

```
      [,1]
[1,] 9357.62824
[2,] -999.76784
[3,] 279.84741
[4,] -193.88870
```

Analyse des données haute fréquence

Pour les séries à haute fréquence (hebdomadaires, journalières, horaires, etc.)

- Les effets calendaires peuvent être relativement importants (notamment les jours fériés)

Analyse des données haute fréquence

Pour les séries à haute fréquence (hebdomadaires, journalières, horaires, etc.)

- Les effets calendaires peuvent être relativement importants (notamment les jours fériés)
- On peut utiliser des modèles avec des régresseurs externes (e.g. fourrier)

Analyse des données haute fréquence

Pour les séries à haute fréquence (hebdomadaires, journalières, horaires, etc.)

- Les effets calendaires peuvent être relativement importants (notamment les jours fériés)
- On peut utiliser des modèles avec des régresseurs externes (e.g. fourrier)
- TBATS

Analyse des données haute fréquence

Pour les séries à haute fréquence (hebdomadaires, journalières, horaires, etc.)

- Les effets calendaires peuvent être relativement importants (notamment les jours fériés)
- On peut utiliser des modèles avec des régresseurs externes (e.g. fourrier)
- TBATS
- On peut combiner des modèles STL + ETS ou ARIMA sur série désaisonnalisée

Analyse des données haute fréquence

Pour les séries à haute fréquence (hebdomadaires, journalières, horaires, etc.)

- Les effets calendaires peuvent être relativement importants (notamment les jours fériés)
- On peut utiliser des modèles avec des régresseurs externes (e.g. fourrier)
- TBATS
- On peut combiner des modèles STL + ETS ou ARIMA sur série désaisonnalisée

Analyse des données haute fréquence


Pour les séries à haute fréquence (hebdomadaires, journalières, horaires, etc.)

- Les effets calendaires peuvent être relativement importants (notamment les jours fériés)
- On peut utiliser des modèles avec des régresseurs externes (e.g. fourrier)
- TBATS
- On peut combiner des modèles STL + ETS ou ARIMA sur série désaisonnalisée

Voir <https://otexts.com/fpp2/weekly.html> et <https://otexts.com/fpp3/weekly.html> pour des exemples

Exemples (1)

```
library(forecast);library(ggplot2);library(patchwork)
y <- fpp2::gasoline
autoplot(y, main = "Essence")
```




Exemples (2)

```
frequency(y)
```


```
[1] 52.17857
```

```
ggseasonplot(y, polar = TRUE)
```

Seasonal plot: y



year



Exemples (3)

```
# Saisonnalité annuelle et mensuelle :
tbats <- tbats(y, seasonal.periods = c(365.25/7, 365.25/12/7))
arima_fourier <- auto.arima(y, seasonal = FALSE, xreg = fourier(y,K=5))
tbats
```

TBATS(1, {0,0}, 0.8, {<4.35,6>, <52.18,1>})

Call: tbats(y = y, seasonal.periods = c(365.25/7, 365.25/12/7))

Parameters

Alpha: 0.2350472

Beta: -0.03474354

Damping Parameter: 0.800008

Gamma-1 Values: -0.0002755258 6.336552e-05


Gamma-2 Values: 5.566591e-05 5.769457e-05

Seed States:

```
[,1]
[1,] 6.949478933
[2,] 0.021926676
[3,] -0.030850684
[4,] 0.006212825
[5,] -0.009773578
```

Exemples (4)


```
autoplot(window(y, start = 2010)) +  
  autolayer(forecast(tbats, h = 52*2)$mean, series="TBATS")+  
  autolayer(forecast(arima_fourier, h = 52*2, xreg = fourier(y, K=5, h = 52*2)  
            series = "ARIMA + Fourier")
```



Exemples analyse de K (1)

Forecasts from Regression with ARIMA(3,1,5) errors


$K = 1$, AICc = 222.9



Exemples analyse de K (2)

Forecasts from Regression with ARIMA(3,1,5) errors


$K = 2$, AICc = 209.0



Exemples analyse de K (3)

Forecasts from Regression with ARIMA(0,1,1) errors


$K = 3$, AICc = 124.3



Exemples analyse de K (4)

Forecasts from Regression with ARIMA(0,1,1) errors


$K = 4$, AICc = 109.1



Exemples analyse de K (5)

Forecasts from Regression with ARIMA(0,1,1) errors


$K = 5$, AICc = 86.8



Exemples analyse de K (6)

Forecasts from Regression with ARIMA(0,1,3) errors


$K = 6$, AICc = 35.3



Exemples analyse de K (7)

Forecasts from Regression with ARIMA(0,1,3) errors


$K = 7$, AICc = 8.2



Exemples analyse de K (8)

Forecasts from Regression with ARIMA(0,1,3) errors


$K = 8$, AICc = 1.2



Exemples analyse de K (9)

Forecasts from Regression with ARIMA(4,1,1) errors


$K = 9$, $AICc = -7.3$



Exemples analyse de K (10)

Forecasts from Regression with ARIMA(4,1,1) errors

$K = 10$, AICc = -20.0



Modèles ECM

Les modèles à correction d'erreur (ECM) permettent de mettre en relation deux variables x_t, y_t non-stationnaires qui partagent la même tendance stochastique. Modèle suivant est utilisé :

$$\Delta y_t = \gamma + \underbrace{\sum_{i=1}^p \Delta y_{t-i} + \sum_{i=1}^p \Delta x_{t-i}}_{\text{court terme}} + \alpha \underbrace{(y_{t-1} - \beta_0 - \beta_1 x_{t-1})}_{\text{long terme}} + \varepsilon_t$$

Modèles ECM

Les modèles à correction d'erreur (ECM) permettent de mettre en relation deux variables x_t, y_t non-stationnaires qui partagent la même tendance stochastique. Modèle suivant est utilisé :

$$\Delta y_t = \gamma + \underbrace{\sum_{i=1}^p \Delta y_{t-i} + \sum_{i=1}^p \Delta x_{t-i}}_{\text{court terme}} + \alpha \underbrace{(y_{t-1} - \beta_0 - \beta_1 x_{t-1})}_{\text{long terme}} + \varepsilon_t$$

Peut s'estimer par double MCO : long terme puis court terme sur les résidus. On peut s'aider de `dynlm::dynlm()` ou utiliser le package `ecm`.

Modèles ECM

Les modèles à correction d'erreur (ECM) permettent de mettre en relation deux variables x_t, y_t non-stationnaires qui partagent la même tendance stochastique. Modèle suivant est utilisé :

$$\Delta y_t = \gamma + \underbrace{\sum_{i=1}^p \Delta y_{t-i} + \sum_{i=1}^p \Delta x_{t-i}}_{\text{court terme}} + \alpha \underbrace{(y_{t-1} - \beta_0 - \beta_1 x_{t-1})}_{\text{long terme}} + \varepsilon_t$$

Peut s'estimer par double MCO : long terme puis court terme sur les résidus. On peut s'aider de `dynlm::dynlm()` ou utiliser le package `ecm`.

Pour que le modèle soit valide il faut que $y_{t-1} - \beta_0 - \beta_1 x_{t-1}$ soit stationnaire : on peut faire un test de racine unité sur les résidus ou appliquer le test de Johansen (`urca::ca.jo`).

Modèles ECM

Les modèles à correction d'erreur (ECM) permettent de mettre en relation deux variables x_t, y_t non-stationnaires qui partagent la même tendance stochastique. Modèle suivant est utilisé :

$$\Delta y_t = \gamma + \underbrace{\sum_{i=1}^p \Delta y_{t-i} + \sum_{i=1}^p \Delta x_{t-i}}_{\text{court terme}} + \underbrace{\alpha (y_{t-1} - \beta_0 - \beta_1 x_{t-1})}_{\text{long terme}} + \varepsilon_t$$



Peut s'estimer par double MCO : long terme puis court terme sur les résidus. On peut s'aider de `dynlm::dynlm()` ou utiliser le package `ecm`.

Pour que le modèle soit valide il faut que $y_{t-1} - \beta_0 - \beta_1 x_{t-1}$ soit stationnaire : on peut faire un test de racine unité sur les résidus ou appliquer le test de Johansen (`urca::ca.jo`).

Généralement $\alpha < 0$: s'interprète comme une force de rappel.

Exemple (1)

```
# install.packages("PepperPrice")
library(urca);library(dynlm);library(forecast);library(ggplot2)
data("PepperPrice", package = "AER")
# On passe au log pour analyser les différences comme des évolutions
data_pepper <- log(PepperPrice)
autoplot(data_pepper) / autoplot(diff(data_pepper))
```



Exemple (2)

```
# Séries sont dites I(1) :  
# Elles ne sont pas stationnaires  
tseries::kpss.test(data_pepper[, "black"])
```

KPSS Test for Level Stationarity

```
data: data_pepper[, "black"]  
KPSS Level = 0.60007, Truncation lag parameter = 5, p-value = 0.02263  
tseries::kpss.test(data_pepper[, "white"])
```

KPSS Test for Level Stationarity

```
data: data_pepper[, "white"]  
KPSS Level = 0.61733, Truncation lag parameter = 5, p-value = 0.02106  
# Mais les séries différenciées le sont  
tseries::kpss.test(diff(data_pepper[, "black"], 1))
```

Exemple (3)

KPSS Test for Level Stationarity

```
data: diff(data_pepper[, "black"], 1)
KPSS Level = 0.15877, Truncation lag parameter = 5, p-value = 0.1
tseries::kpss.test(diff(data_pepper[, "white"], 1))
```

KPSS Test for Level Stationarity

```
data: diff(data_pepper[, "white"], 1)
KPSS Level = 0.13062, Truncation lag parameter = 5, p-value = 0.1
# Le test de Johansen doit se lire de manière croissante avec r
# r=0 signifie qu'il n'y a pas de relation de co-intégration
# si on le rejette (test > valeurs critiques), on regarde le test suivant
# Dans notre cas il n'y a que deux tests car on a que deux variables
# Le test est plus général pour les cas où l'on fait des VECM
# (potentiellement plusieurs relations de cointegration)
# Ici on conclut qu'il y a bien relation de cointegration
summary(ca.jo(data_pepper))
```

Exemple (4)

```
#####
# Johansen-Procedure #
#####
```

Test type: maximal eigenvalue statistic (lambda max) , with linear trend

Eigenvalues (lambda):

```
[1] 0.04923322 0.01262841
```

Values of teststatistic and critical values of test:

	test	10pct	5pct	1pct
r <= 1	3.42	6.50	8.18	11.65
r = 0	13.58	12.91	14.90	19.19

Eigenvectors, normalised to first column:

(These are the cointegration relations)

	black.l2	white.l2
black.l2	1.0000000	1.0000000

Exemple (5)

```
white.l2 -0.8904272 -6.177004
```


Weights W:

(This is the loading matrix)

```
           black.l2    white.l2  
black.d -0.07423986  0.001970073  
white.d  0.02088163  0.002811481
```

```
# On estime la relation de long-terme  
lm_lt <- lm(black ~ white, data = data_pepper)  
resid_lt <- ts(residuals(lm_lt), start = start(data_pepper),  
               frequency = frequency(data_pepper))  
autoplot(resid_lt)
```

Exemple (6)



```
# La série est bien stationnaire  
tseries::kpss.test(resid_lt)
```

KPSS Test for Level Stationarity


data: resid_lt

KPSS Level = 0.23504, Truncation lag parameter = 5, p-value = 0.1

Exemple (7)

```
# Rmq il y a quelques points atypiques que l'on pourrait corriger
# en ajoutant par exemple des indicatrices
# On peut aussi utiliser la fonction forecast::tsoutliers() pour les repérer
# En reprenant le code disponible ici
# https://robjhyndman.com/hyndsight/tsoutliers/ :
autoplot(tsclean(resid_lt), series="clean", color='red', lwd=0.9) +
  autolayer(resid_lt, series="original", color='gray', lwd=1) +
  geom_point(data = tsoutliers(resid_lt) %>% as.data.frame(),
            aes(x=time(resid_lt)[index], y=replacements), col='blue')
```

Exemple (8)



```
data <- ts.union(data_pepper, resid_lt)
colnames(data) <- c(colnames(data_pepper), "long_term")
# On a bien une force de rappel négative
summary(
  dynlm(diff(black, 1) ~ lag(diff(black, 1), -1) +
        lag(diff(white, 1), -1) +
        lag(long_term, -1), data = data)
)
```

Exemple (9)

Time series regression with "ts" data:

Start = 1973(12), End = 1996(4)

Call:

```
dynlm(formula = diff(black, 1) ~ lag(diff(black, 1), -1) + lag(diff(white,
  1), -1) + lag(long_term, -1), data = data)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.200930	-0.035547	-0.005632	0.028757	0.228076

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.001830	0.003876	0.472	0.63724
lag(diff(black, 1), -1)	0.327341	0.069431	4.715	3.92e-06 ***
lag(diff(white, 1), -1)	0.051700	0.069819	0.740	0.45966
lag(long_term, -1)	-0.072551	0.027006	-2.686	0.00768 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Exemple (10)

Residual standard error: 0.06345 on 265 degrees of freedom
Multiple R-squared: 0.144, Adjusted R-squared: 0.1343
F-statistic: 14.86 on 3 and 265 DF, p-value: 5.698e-09